

第十九讲：条件数学期望与母函数

Email: xzhangseu@seu.edu.cn



- ▶ 在第二章中对于任何有正概率的事件 B , 我们引入了条件概率 $P(\cdot|B)$ 及条件分布 $F(x|B) := P(X \leq x|B)$;
- ▶ 类似于概率与分布函数, 对于上述的条件概率及条件分布, 我们也可以定义相应的条件数学期望:

定义 0.1 如果下述积分绝对收敛, 则称

$$E(X|B) := \int_{-\infty}^{+\infty} x dF(x|B) = \int_{\Omega} X(\omega) dP(\omega|B)$$

为已知事件 B 发生后 X 的条件数学期望.

条件数学期望的两类特殊情形：离散型与连续型



定理 0.1 若 X, Y 均为离散型随机变量，并且条件数学期望定义中的 B 选为 $B := \{Y = y_j\}$ 的形式，则

$$E(X|Y = y_j) = \int_{-\infty}^{+\infty} x dF(x|Y = y_j) = \sum_i x_i P(X = x_i|Y = y_j)$$

定理 0.2 若 X, Y 均为连续型随机变量，并且条件数学期望定义中的 B 选为 $B := \{Y = y\}$ 的形式，则

$$E(X|Y = y) = \int_{-\infty}^{+\infty} x dF(x|Y = y) = \int_{-\infty}^{+\infty} xp(x|y)dx$$



定理 0.3 设 $g(x)$ 为 Borel 函数, 则 $g(X)$ 关于 $Y=y$ 的条件期望为

$$E(g(X)|Y=y) = \int_{-\infty}^{+\infty} g(x)dF(x|y)$$

定义 0.2 假设 X 的方差存在, 则称

$$\begin{aligned} D(X|Y=y) &:= E[(X - E(X|Y=y))^2|Y=y] \\ &= \int_{-\infty}^{+\infty} (x - E(X|Y=y))^2 dF(x|y) \end{aligned}$$

为给定 $Y=y$ 后 X 的条件方差.



定理 0.4 设 X 为随机变量, B 为任意事件, 且 $P(B) > 0$, 则

$$\begin{aligned} E(X|B) &= \frac{1}{P(B)} E(X1_B) \\ &= \frac{1}{P(B)} \int_{\Omega} X(\omega) 1_B(\omega) dP(\omega) = \frac{1}{P(B)} \int_B X(\omega) dP(\omega) \end{aligned}$$

条件数学期望与数学期望之间的联系



▶ 若 $X = 1_A$, 则 $E(X|B) = P(A|B) = \frac{P(A \cap B)}{P(B)} = \frac{E(1_A 1_B)}{P(B)} = \frac{E(X 1_B)}{P(B)}$;

▶ 若 $X = \sum_{i=1}^n a_i 1_{A_i}$, 则

$$\begin{aligned} E(X|B) &= \sum_{i=1}^n a_i P(A_i|B) = \sum_{i=1}^n a_i \frac{P(A_i \cap B)}{P(B)} \\ &= \frac{1}{P(B)} \sum_{i=1}^n a_i E(1_{A_i} 1_B) = \frac{1}{P(B)} E(X 1_B); \end{aligned}$$

▶ 对任意非负随机变量 X , 存在简单随机变量 $X_n \uparrow X$, 从而

$$\begin{aligned} E(X|B) &= \lim_{n \rightarrow \infty} E(X_n|B) = \lim_{n \rightarrow \infty} \frac{1}{P(B)} E(X_n 1_B) \\ &= \frac{1}{P(B)} \lim_{n \rightarrow \infty} E(X_n 1_B) = \frac{1}{P(B)} E(X 1_B); \end{aligned}$$

▶ 对任意随机变量 $X = X^+ - X^-$, 则

$$E(X|B) = \frac{1}{P(B)} E(X^+ 1_B) - \frac{1}{P(B)} E(X^- 1_B) = \frac{1}{P(B)} E(X 1_B).$$



- ▶ 如何理解条件概率 $P(A|B) = \frac{P(AB)}{P(B)}$:
 - ▶ 对随机变量 1_A 的最优常数估计为: $E(1_A) = P(A)$;
 - ▶ 已知 B 发生的条件下对 1_A 的最优常数估计为: $E(1_A|B) = P(A|B)$;
 - ▶ 条件概率 $P(A|B)$ 也可看作在已知事件 B 发生的条件下对事件 A 发生概率 $P(A)$ 的一个估计.
- ▶ 如何理解条件数学期望 $E(X|B)$:
 - ▶ 对随机变量 X 的最优常数估计为: $E(X)$;
 - ▶ 已知事件 B 发生的条件下对 X 的最优常数估计为: $E(X|B)$;
 - ▶ 条件数学期望 $E(X|B)$ 也可看作在已知事件 B 发生的条件下对 X 的数学期望 $E(X)$ 的一个估计.
- ▶ 若已知 $\mathcal{G} = \{\emptyset, B, \bar{B}, \Omega\}$, 如何定义 $E(X|\mathcal{G})$, 即寻找已知 σ -代数 $\mathcal{G}$ 下 X 的最优预测或估计?
 - ▶ 若 $\omega \in B$, 则 X 的最优预测或估计 $E(X|\mathcal{G})(\omega) = E(X|B)$;
 - ▶ 若 $\omega \in \bar{B}$, 则 X 的最优预测或估计 $E(X|\mathcal{G})(\omega) = E(X|\bar{B})$;
 - ▶ 因此 $E(X|\mathcal{G}) = E(X|B)1_B(\omega) + E(X|\bar{B})1_{\bar{B}}(\omega)$;
 - ▶ 上述定义的 $E(X|\mathcal{G})$ 关于 $\mathcal{G}$ 可测, 且满足

$$\int_G E(X|\mathcal{G})dP = \int_G XdP, \quad \forall G \in \mathcal{G};$$



定义 0.3 设 $\{B_i, i \in I\} \subset \mathcal{F}$ 为 Ω 的一个划分且 $P(B_i) > 0$. 令 $\mathcal{G} = \sigma(\{B_i, i \in I\})$ 为由该划分生成的 σ -代数, 则称随机变量

$$Z = \sum_{i \in I} E(X|B_i) 1_{B_i}(\omega)$$

为随机变量 X 关于 σ -代数 $\mathcal{G}$ 的条件数学期望, 并将其记为 $E(X|\mathcal{G})$.



$E(X|\sigma(\{B_i, i \in I\}))$ 的性质

定理 0.5 上述定义的 $E(X|\mathcal{G})$ 关于 $\mathcal{G}$ 可测, 且满足

$$\int_G E(X|\mathcal{G})dP = \int_G XdP, \quad \forall G \in \mathcal{G}.$$

证明: 显然, $E(X|\mathcal{G})$ 关于 $\mathcal{G}$ 可测. 若 $G \in \mathcal{G} = \sigma(\{B_i, i \in I\})$, 则必有

$$G = \cup_{i \in J} B_i, \quad J \subset I.$$

因此,

$$\begin{aligned} \int_G XdP &= \int_{\cup_{i \in J} B_i} XdP = \sum_{i \in J} \int_{B_i} XdP = \sum_{i \in J} \int_{\Omega} X1_{B_i}dP \\ &= \sum_{i \in J} E(X|B_i)P(B_i) = \sum_{i \in J} \int_{B_i} E(X|B_i)dP \\ &= \sum_{i \in J} \int_{B_i} E(X|\mathcal{G})dP = \int_{\cup_{i \in J} B_i} E(X|\mathcal{G})dP \\ &= \int_G E(X|\mathcal{G})dP, \quad \forall G \in \mathcal{G}; \end{aligned}$$



定义 0.4 设 $\mathcal{G}$ 为 σ -代数且 $\mathcal{G} \subset \mathcal{F}$, 我们称随机变量 Z 为可积随机变量 X 关于 σ -代数 $\mathcal{G}$ 的条件数学期望, 如果

- ▶ Z 关于 $\mathcal{G}$ 可测;
- ▶ 对任意 $G \in \mathcal{G}$ 有

$$\int_G Z dP = \int_G X dP.$$

注 0.1

- ▶ 此处定义的 Z 在几乎处处相等意义下是否唯一存在?
- ▶ 我们常把上述定义的 Z 记为 $E(X|\mathcal{G})$.
- ▶ 若取 $G = \Omega$, 则有 $EZ = \int_{\Omega} Z dP = \int_{\Omega} X dP = EX$, 也即

$$E[E(X|\mathcal{G})] = EX.$$



- ▶ 若 $\mathcal{G} = \{\emptyset, \Omega\}$, 则 $E(X|\mathcal{G}) = EX$;
- ▶ 若 X 关于 $\mathcal{G}$ 可测, 则 $E(X|\mathcal{G}) = X$;
- ▶ 若 X 与 $\mathcal{G}$ 独立, 则 $E(X|\mathcal{G}) = EX$;
- ▶ 若 $\mathcal{G}_1 \subset \mathcal{G}_2 \subset \mathcal{F}$, 则

$$E[E(X|\mathcal{G}_2)|\mathcal{G}_1] = E(X|\mathcal{G}_1);$$

- ▶ 若 X, Y 均为可积随机变量, 且 a, b 为常数, 则

$$E(aX + bY|\mathcal{G}) = aE(X|\mathcal{G}) + bE(Y|\mathcal{G});$$

- ▶ 若 $X \leq Y$ 几乎处处成立, 则

$$E(X|\mathcal{G}) \leq E(Y|\mathcal{G}) \text{ 几乎处处成立};$$

- ▶ 若 Y 关于 $\mathcal{G}$ 可测, 则

$$E(XY|\mathcal{G}) = YE(X|\mathcal{G}).$$

条件数学期望的最优预测性



定理 0.6 设 $\mathcal{G}$ 为 σ -代数且 $\mathcal{G} \subset \mathcal{F}$, 则对任意 $\mathcal{F}$ 可测的可积随机变量 X 及 $\mathcal{G}$ -可测随机变量 Z 有

$$E[(X - E(X|\mathcal{G}))^2] = \inf_{Z \in \mathcal{G}} E[(X - Z)^2].$$

证明: 对任意 $\mathcal{G}$ -可测随机变量 Z , 有

$$\begin{aligned} E[(X - Z)^2] &= E[(X - E(X|\mathcal{G})) + (E(X|\mathcal{G}) - Z)]^2 \\ &= E[(X - E(X|\mathcal{G}))^2] + E[(E(X|\mathcal{G}) - Z)^2] \\ &\quad + 2E[(X - E(X|\mathcal{G}))(E(X|\mathcal{G}) - Z)] \end{aligned}$$

注意到

$$\begin{aligned} E[(X - E(X|\mathcal{G}))(E(X|\mathcal{G}) - Z)] &= E\left[E((X - E(X|\mathcal{G}))(E(X|\mathcal{G}) - Z)|\mathcal{G})\right] \\ &= E\left[(E(X|\mathcal{G}) - Z)E(X - E(X|\mathcal{G})|\mathcal{G})\right] = 0 \end{aligned}$$

故 $E[(X - Z)^2] = E[(X - E(X|\mathcal{G}))^2] + E[(E(X|\mathcal{G}) - Z)^2] \geq E[(X - E(X|\mathcal{G}))^2]$.



定理 0.7 设 $\mathcal{G}$ 为 σ -代数且 $\mathcal{G} \subset \mathcal{F}$, 则对任意有界 $\mathcal{G}$ 可测随机变量 Z 均有

$$E[(X - E(X|\mathcal{G}))Z] = 0.$$

证明:

- ▶ 由条件数学期望的定义可知, 对任意的 $G \in \mathcal{G}$ 均有

$$E[(X - E(X|\mathcal{G}))1_G] = 0$$

- ▶ 从而, 对任意的简单函数 $Z = \sum_{i=1}^n a_i 1_{G_i}$, 其中 $G_i \in \mathcal{G}$, 均有

$$E[(X - E(X|\mathcal{G}))Z] = \sum_{i=1}^n a_i E[(X - E(X|\mathcal{G}))1_{G_i}] = 0.$$

- ▶ 由于有界 $\mathcal{G}$ 可测随机变量 Z 可由有界简单函数逼近, 故由控制收敛定理可知对任意有界 $\mathcal{G}$ 可测随机变量 Z 均有

$$E[(X - E(X|\mathcal{G}))Z] = 0.$$



- ▶ 随机变量 X 关于随机变量 Y 的条件数学期望:

$$E(X|Y) := E(X|\sigma(Y)).$$

- ▶ 根据 PPT267 页定理 2.4 可知, 存在博雷尔可测函数 $\varphi(\cdot)$ 使得

$$E(X|Y) = \varphi(Y).$$

- ▶ 我们也常把上述的函数 $\varphi(\cdot)$ 记作 $\varphi(y) := E(X|Y=y)$.
 - ▶ 若 Y 为离散型随机变量, 则上述的博雷尔函数 $\varphi(y_j) = E(X|Y=y_j)$;
 - ▶ 若 (X, Y) 为二维连续型随机向量, 且其联合分布密度为 $p(x, y)$, 则上述的博雷尔函数

$$\varphi(y) = E(X|Y=y) = \int_{-\infty}^{+\infty} xp(x|y)dx,$$

其中 $p(x|y) = \frac{p(x, y)}{p_Y(y)}$ 为 X 关于 Y 的条件分布密度.

例 0.1 若 $(X, Y) \sim N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$, 则

$$E(X|Y=y) = \mu_1 + \rho \frac{\sigma_1}{\sigma_2}(y - \mu_2).$$

证明: 在第二章中, 我们知道给定 $Y=y$ 下, X 的条件分布服从

$$N(\mu_1 + \rho \frac{\sigma_1}{\sigma_2}(y - \mu_2), \sigma_1^2(1 - \rho^2))$$

故

$$\varphi(y) = E(X|Y=y) = \mu_1 + \rho \frac{\sigma_1}{\sigma_2}(y - \mu_2)$$

更进一步地, 我们有

$$E(X|Y) = \varphi(Y) = \mu_1 + \rho \frac{\sigma_1}{\sigma_2}(Y - \mu_2)$$

条件数学期望的性质：重期望（全期望）公式



定理 0.8 设 $\mathcal{G}$ 为 σ -代数且 $\mathcal{G} \subset \mathcal{F}$, 则对随机变量 X 及任意 Borel 函数 $g(x)$ 有

$$E[E(g(X)|\mathcal{G})] = E(g(X)), \text{ 或, } \int_{\Omega} E(g(X)|\mathcal{G})dP = \int_{\Omega} g(X)dP.$$

特别的,

► 若 $\mathcal{G} = \sigma(Y)$, 则有

$$E[E(g(X)|Y)] = E(g(X)), \text{ 或, } \int_{\Omega} E(g(X)|Y)dP = \int_{\Omega} g(X)dP.$$

► 若 $\mathcal{G} = \sigma(\{B_i, i \in I\})$, 则有

$$E\left[\sum_{i \in I} E(g(X)|B_i)1_{B_i}(\omega)\right] = E(g(X)), \text{ 或, } E[g(X)] = \sum_{i \in I} E(g(X)|B_i)P(B_i).$$

条件数学期望的性质：重期望（全期望）公式



证明：由条件数学期望定义的第 2 条可知对任意 $G \in \mathcal{G}$ 有

$$\int_G E(g(X)|\mathcal{G})dP = \int_G g(X)dP.$$

取 $G = \Omega$, 则有

$$E[E(g(X)|\mathcal{G})] = \int_{\Omega} E(g(X)|\mathcal{G})dP = \int_{\Omega} g(X)dP = E(g(X)).$$

重期望公式关于分布函数的 Stieltjes 积分表达式



- ▶ 注意到, $E(g(X)|Y) = \varphi(Y)$, 其中 $\varphi(y) := E(g(X)|Y = y)$;
- ▶ 故上述定理的重期望公式可写成如下形式

$$\begin{aligned} E(g(X)) &= \int_{-\infty}^{+\infty} E[g(X)|Y = y] dF_Y(y) \\ &= \begin{cases} \sum_j E(g(X)|Y = y_j) P(Y = y_j) \\ \int_{-\infty}^{+\infty} E(g(X)|Y = y) p_Y(y) dy \end{cases} \end{aligned}$$

- ▶ 特别的, 若 $g(X) = X$, 则有

$$\begin{aligned} E(X) &= \int_{-\infty}^{+\infty} E[X|Y = y] dF_Y(y) \\ &= \begin{cases} \sum_j E(X|Y = y_j) P(Y = y_j) \\ \int_{-\infty}^{+\infty} E(X|Y = y) p_Y(y) dy \end{cases} \end{aligned}$$

例 0.2 一个窃贼被关在有 3 个门的地牢中。其中 1 号门通向自由，出 1 号门后走 3 个小时便回到地面；2 号门通向一个地道，在此地道走 5 个小时后返回地牢；3 号门通向一个更长的地道，沿这个地道走 7 个小时后回到地牢。如果窃贼每次选择 3 个门的可能性总相等，求他为获自由而奔走的平均时间。

解： 设窃贼需要走 X 小时到达地面，则 X 的所有可能取值为

$$3, 5 + 3, 7 + 3, 5 + 5 + 3, 5 + 7 + 3, 7 + 7 + 3, \dots,$$

则显然要写出 X 的分布列是困难的，所以无法直接求 $E(X)$ 。但是如果引入 Y 表示窃贼每次对 3 个门的选择，则

$$P(Y=1) = P(Y=2) = P(Y=3) = 1/3$$

$$E(X|Y=1) = 3, E(X|Y=2) = 5 + E(X), E(X|Y=3) = 7 + E(X)$$

从而由重期望公式可得

$$E(X) = \sum_{i=1}^3 E(X|Y=i)P(Y=i) = 5 + \frac{2}{3}E(X) \Rightarrow E(X) = 15$$

定理 0.9 设 $X_1, X_2, \dots$, 为一列独立同分布的随机变量, 随机变量 N 只取正整数值, 且 N 与 $\{X_n\}$ 独立, 则

$$E\left(\sum_{i=1}^N X_i\right) = E(X_1)E(N)$$

证明: 由重期望公式可知

$$\begin{aligned} E\left(\sum_{i=1}^N X_i\right) &= E\left[E\left(\sum_{i=1}^N X_i \mid N\right)\right] = \sum_{n=1}^{+\infty} E\left(\sum_{i=1}^N X_i \mid N=n\right)P(N=n) \\ &= \sum_{n=1}^{+\infty} E\left(\sum_{i=1}^n X_i \mid N=n\right)P(N=n) = \sum_{n=1}^{+\infty} E\left(\sum_{i=1}^n X_i\right)P(N=n) \\ &= \sum_{n=1}^{+\infty} nE(X_1)P(N=n) = E(X_1)E(N) \end{aligned}$$

定义 0.5 如果 $E|X|^k < +\infty$, 则称 $m_k := E(X^k)$ 为随机变量 X (及其分布) 的 k 阶原点矩。而称 $c_k := E(X - EX)^k$ 为随机变量 (及其分布) 的 k 阶中心矩。

定理 0.10 当 $E|X|^k < +\infty$ 时有,

$$c_k = \sum_{i=0}^k C_k^i (-m_1)^{k-i} m_i, \quad m_k = \sum_{i=0}^k C_k^i c_{k-i} m_1^i.$$

证明: 注意到

$$\begin{aligned} (X - EX)^k &= \sum_{i=0}^k C_k^i X^i (-EX)^{k-i}, \\ X^k &= (EX + X - EX)^k = \sum_{i=0}^k C_k^i (EX)^i (X - EX)^{k-i} \end{aligned}$$

对上面两式取期望即可得证。

定义 0.6 对任何实数列 $\{p_n\}$, 如果幂级数

$$G(s) = \sum_{n=0}^{\infty} p_n s^n \quad (1)$$

的收敛半径 $s_0 > 0$, 则称 $G(s)$ 为数列 $\{p_n\}$ 的母函数。特别当 $\{p_n\}$ 为某非负整值随机变量 X 的概率分布时, (1) 式至少在区间 $[-1, 1]$ 上绝对收敛且一致收敛, 此时有

$$G(s) = E(s^X),$$

称此 $G(s)$ 为随机变量 X 或其概率分布 $\{p_n\}$ 的母函数。



► 已知 $G(s)$, 如何确定 $\{p_n\}$?

► 注意到

$$G(0) = p_0, \quad G^{(n)}(s) = n!p_n + \sum_{k=n+1}^{\infty} k(k-1)\cdots(k-n+1)p_k s^{k-n}$$

► 故

$$p_n = \frac{1}{n!} G^{(n)}(0)$$

► 非负整值概率分布 $\{p_n\}$ 与其母函数 $G(s)$ 是一一对应的, 母函数可以作为描述这种分布的一种工具.



定理 0.11 设非负随机变量 X 的母函数为 $G(s)$, 如果 $E(X)$ 与 $E(X^2)$ 有限, 则

$$G'(1) = E(X), \quad G''(1) = E(X^2) - E(X)$$



► Poisson 分布的母函数

$$G(s) = E(s^X) = \sum_{k=0}^{\infty} s^k \frac{\lambda^k}{k!} e^{-\lambda} = e^{\lambda(s-1)}$$

► 几何分布的母函数

$$G(s) = E(s^X) = \sum_{k=1}^{\infty} s^k q^{k-1} p = \frac{ps}{1 - qs}$$

定理 0.12 如果 X, Y 为相互独立的随机变量, 它们分别有概率分布 $\{a_n\}, \{b_n\}$ 及对应的母函数 $A(s), B(s)$, 则它们的和 $X + Y$ 的母函数为

$$C(s) = A(s)B(s).$$

更进一步, 如果 $X_1, \dots, X_n$ 相互独立, 其对应的母函数分别为 $A_1(s), \dots, A_n(s)$, 则 $X_1 + \dots + X_n$ 的母函数为

$$C(s) = \prod_{i=1}^n A_i(s)$$

证明: 注意到由 X, Y 相互独立可知 s^X, s^Y 也相互独立, 从而

$$C(s) = E(s^{X+Y}) = E(s^X s^Y) = E(s^X)E(s^Y) = A(s)B(s)$$

例 0.3 设 X 服从二项分布 $B(n, p)$, 则 X 的母函数为 $G(s) = (q + ps)^n$.

随机个非负整值随机量之和的母函数



定理 0.13 设 $\{X_k\}$ 为相互独立同分布的非负整值随机变量序列，其共同的母函数为 $G(s)$. 如果 N 为另一非负整值随机变量，其母函数为 $F(s)$. 则当 N 与每一个 X_k 均独立时， $X = \sum_{k=1}^N X_k$ 的母函数为

$$H(s) = F(G(s)).$$

证明： 由重期望公式可得

$$\begin{aligned} H(s) &= E(s^X) = E(E(s^X|N)) = \sum_{n=0}^{\infty} P(N=n) E(s^{\sum_{k=1}^N X_k} | N=n) \\ &= \sum_{n=0}^{\infty} P(N=n) E(s^{\sum_{k=1}^n X_k} | N=n) = \sum_{n=0}^{\infty} P(N=n) E(s^{\sum_{k=1}^n X_k}) \\ &= \sum_{n=0}^{\infty} P(N=n) [G(s)]^n = E(G(s)^N) \\ &= F(G(s)) \end{aligned}$$



- 对 $H(s)$ 求导可得

$$H'(s) = F'(G(s))G'(s)$$

- 令 $s = 1$ 并注意到 $G(1) = 1$ 可得

$$E(X) = E(N)E(X_1)$$

- 再对 $H'(s)$ 求导可得

$$H''(s) = F''(G(s))[G'(s)]^2 + F'(G(s))G''(s)$$

- 令 $s = 1$ 可得

$$\begin{aligned} E(X^2) - E(X) &= [E(N^2) - E(N)][E(X_1)]^2 + E(N)[E(X_1^2) - E(X_1)] \\ &= E(N)D(X_1) + E(N^2)[E(X_1)]^2 - E(N)E(X_1) \end{aligned}$$

- 从而

$$D(X) = E(X^2) - [E(X)]^2 = E(N)D(X_1) + D(N)[E(X_1)]^2$$